

Laporan Eksperimen Klasifikasi Citra Biner: CNN dari Dasar vs Transfer Learning MobileNetV2

Ringkasan

Laporan eksperimen ini menyajikan studi perbandingan performa antara arsitektur *Convolutional Neural Network* (CNN) yang dibangun dari dasar (*from scratch*) dengan pendekatan *Transfer Learning* memanfaatkan model pretrained MobileNetV2. Eksperimen dilakukan pada pengenalan subset biner dari dataset CIFAR-10 yang disaring secara khusus untuk membedakan dua kelas, yaitu kelas Kucing (label 0) dan kelas Anjing (label 1). Model CNN *from scratch* dilatih selama 20 epoch menggunakan optimasi Adam dengan teknik regularisasi berupa *Batch Normalization* dan *Dropout*, sementara model *Transfer Learning* menggunakan MobileNetV2 yang dibekukan layer dasarnya (*feature extraction*) dilatih selama 10 epoch. Hasil eksperimen menunjukkan temuan yang kontras dan menarik: model CNN *from scratch* berhasil mencapai akurasi training sebesar 84,63% dan akurasi validasi sebesar 72,50%. Sebaliknya, model *Transfer Learning* dengan MobileNetV2 hanya memperoleh akurasi training sebesar 54,20% dan validasi sebesar 55,60% akibat kendala ketidakcocokan resolusi input bawaan MobileNetV2 dengan dimensi citra CIFAR-10 yang sangat kecil (32×32 piksel). Laporan ini membahas analisis mendalam mengenai performa kedua model, implikasi kualitas dataset, solusi penanganan masalah arsitektur, serta jawaban komprehensif atas studi kasus pengambilan keputusan di dunia nyata.

1 Pendahuluan

Eksperimen ini dilatarbelakangi oleh kebutuhan untuk memahami trade-off antara mendesain arsitektur jaringan saraf dalam dari awal atau memanfaatkan representasi fitur yang telah matang dari model berskala besar melalui teknik transfer learning. Fokus tugas ini adalah melakukan klasifikasi citra biner pada objek yang memiliki variasi spasial tinggi (kucing vs anjing) dengan memanfaatkan subset data yang diekstrak dari dataset CIFAR-10.

2 Deskripsi Dataset

Dataset yang digunakan dalam eksperimen ini adalah CIFAR-10 yang diakses langsung melalui submodul `tf.keras.datasets.cifar10`. Dataset ini terdiri dari total 60.000 citra berwarna berukuran 32×32 piksel yang terbagi ke dalam 10 kelas seimbang. Sesuai dengan instruksi tugas klasifikasi dua kelas (biner), dataset disaring secara spesifik untuk hanya mengekstrak gambar yang tergolong dalam kelas Kucing (*Cat*, label indeks asli 3) dan kelas Anjing (*Dog*, label indeks asli 5).

Komposisi subset data yang berhasil diekstrak dan digunakan dalam eksperimen ini adalah sebagai berikut:

- **Data Training:** Berjumlah 10.000 gambar, yang terdiri atas 5.000 citra kucing dan 5.000 citra anjing (distribusi seimbang 50%:50%).
- **Data Validation:** Berjumlah 1.000 gambar, dipisahkan menggunakan proporsi dari data uji biner asli.

- **Data Testing:** Berjumlah 1.000 gambar, dialokasikan secara acak dan independen dari data validasi untuk pengujian akhir.

Sifat dari dataset ini memiliki variasi internal yang sangat tinggi karena mencakup berbagai ras kucing dan anjing dengan pose tubuh yang berbeda, sudut pengambilan gambar yang bervariasi, pencahayaan yang beragam, serta latar belakang (*background*) yang kompleks (misalnya rumput, karpet, interior rumah, atau area terbuka).

3 Preprocessing Data

Sebelum dimasukkan ke dalam jaringan neural, serangkaian langkah preprocessing diaplikasikan untuk menjamin stabilitas numerik dan kesesuaian format data input:

1. **Penyaringan dan Rekayasa Label:** Memfilter larik NumPy menggunakan fungsi `np.where` untuk mempertahankan citra berlabel 3 dan 5, kemudian mengubah skema representasi label menjadi format biner di mana kelas Kucing dipetakan sebagai nilai 0.0 dan kelas Anjing dipetakan sebagai nilai 1.0 dengan tipe data `float32`.
2. **Pembagian Data (Data Splitting):** Menggunakan fungsi `train_test_split` dari `scikit-learn`.
2. **Normalisasi Piksel (Rescaling):** Nilai asli piksel citra RGB yang berada pada rentang numerik $[0, 255]$ diubah secara linear ke rentang $[0.0, 1.0]$ melalui operasi penskalaan $1./255$. Pada model CNN *from scratch*, operasi ini diintegrasikan langsung sebagai layer pertama di dalam struktur model menggunakan `layers.Rescaling(1./255)` guna efisiensi komputasi berbasis GPU.

4 Implementasi CNN From Scratch

4.1 Desain Arsitektur Jaringan

Model CNN *from scratch* dirancang secara berurutan (*Sequential*) dengan pendekatan modular berbasis blok konvolusi untuk mengekstrak representasi fitur hierarkis secara bertahap:

- **Input Layer:** Menerima matriks citra dengan dimensi $32 \times 32 \times 3$ piksel.
- **Blok Konvolusi 1:** Terdiri atas sebuah lapisan `Conv2D` dengan 32 filter berukuran kernel 3×3 , fungsi aktivasi *Rectified Linear Unit* (ReLU), dan `padding='same'` untuk mempertahankan resolusi spasial. Diikuti oleh lapisan `BatchNormalization` guna menstabilkan distribusi internal aktivasi, lapisan `MaxPooling2D` dengan ukuran window 2×2 untuk mereduksi dimensi spasial menjadi 16×16 , serta lapisan `Dropout(0.25)` untuk mencegah ketergantungan ekstrem antar bobot.
- **Blok Konvolusi 2:** Memiliki struktur serupa dengan blok pertama namun meningkatkan kapasitas ekstraksi fitur dengan menerapkan 64 filter berukuran kernel 3×3 , fungsi aktivasi ReLU, `BatchNormalization`, `MaxPooling2D(2, 2)` (mereduksi dimensi spasial menjadi 8×8), dan `Dropout(0.25)`.
- **Blok Classifier / Fully Connected:** Lapisan `Flatten` digunakan untuk mendatarkan matriks fitur dua dimensi menjadi sebuah vektor tunggal berukuran 4096 elemen ($8 \times 8 \times 64 = 4096$). Vektor ini diumpukan ke lapisan `Dense` dengan 128 neuron (aktivasi ReLU), diperkuat dengan `BatchNormalization`, dan regulasi ketat `Dropout(0.5)` untuk mematikan setengah neuron secara acak saat proses interaksi training berlangsung.
- **Output Layer:** Sebuah lapisan `Dense` dengan 1 neuron yang dikombinasikan dengan fungsi aktivasi *Sigmoid* untuk menghasilkan nilai probabilitas bernilai kontinu $[0, 1]$ yang mengindikasikan kelas target.

4.2 Konfigurasi Training

Model dikompilasi menggunakan fungsi loss `binary_crossentropy` yang ideal untuk optimasi biner. Optimizer yang

5 Implementasi Transfer Learning

5.1 Pemilihan Pretrained Model dan Justifikasi

Untuk pendekatan kedua, arsitektur MobileNetV2 dipilih sebagai model tulang punggung (*backbone pretrained*) yang telah dilatih menggunakan bobot raksasa dari dataset ImageNet. Justifikasi utama pemilihan MobileNetV2 didasarkan pada efisiensi komputasinya yang luar biasa. Model ini menggunakan mekanisme *depthwise separable convolution* yang secara radikal memangkas jumlah parameter aktif dan kebutuhan memori, menjadikannya sangat cocok untuk di-deploy pada perangkat berspesifikasi terbatas atau edge devices tanpa mengorbankan kualitas ekstraksi fitur tingkat tinggi yang telah dipelajari dari ImageNet.

5.2 Strategi Implementasi

Eksperimen ini mengadopsi strategi Feature Extraction murni. Seluruh lapisan bawaan di dalam tubuh MobileNetV2 dibekukan dengan menyetel properti `base_model.trainable = False`. Di atas model ekstraktor fitur yang pasif tersebut, dibangun sebuah kepala klasifikasi (*top classifier*) dengan `units = 1000` dan dilatih selama 10 epoch.

6 Hasil Eksperimen dan Perbandingan Model

Berikut adalah tabel perbandingan komprehensif yang merangkum metrik performa akhir dan karakteristik teknis dari kedua pendekatan berdasarkan data eksekusi riwayat training:

Aspek Perbandingan	CNN From Scratch	Transfer Learning (MobileNetV2)
Akurasi Training (Epoch Terakhir)	84.63%	54.20%
Akurasi Validation (Epoch Terakhir)	72.50%	55.60%
Loss Training (Epoch Terakhir)	0.3449	0.6836
Loss Validation (Epoch Terakhir)	0.5565	0.6820
Waktu Training per Epoch	~1 detik / epoch	~2 detik / epoch
Jumlah Parameter Dapat Dilatih	544,385 parameter	1,281 parameter
Risiko Overfitting	Tinggi ($\Delta \approx 12\%$)	Sangat Rendah (Underfitting)
Kemudahan Implementasi	Sedang	Sangat Mudah
Kesesuaian dengan Ukuran Citra	Sangat Sesuai (32×32)	Tidak Sesuai (Resolusi terlalu kecil)

Tabel 1: Perbandingan Kuantitatif Hasil Eksperimen Klasifikasi Biner

7 Analisis Mendalam Hasil Eksperimen

7.1 Analisis Dataset dan Kualitas Gambar

1. *Kecukupan Ukuran Dataset untuk CNN From Scratch:* Ukuran subset dataset sebanyak 10.000 citra training sebenarnya berada pada batas ambang minimum (*borderline*) untuk melatih model deep learning komparatif dari nol. Mengingat klasifikasi objek kucing dan anjing memiliki kompleksitas visual tinggi, jumlah data tersebut

terbukti cukup bagi model untuk mempelajari fitur-fitur primitif seperti tepian, tekstur bulu, dan bentuk dasar telinga, terbukti dari akurasi training yang melaju hingga 84,63%.

2. *Variasi Gambar dan Ketidakseimbangan Data*: Variasi gambar di dalam CIFAR-10 sangat masif, mencakup sudut pandang makro hingga mikro. Distribusi data antar kelas bersifat seimbang sempurna (5.000 data per kelas), sehingga meniadakan bias algoritma terhadap salah satu kategori objek.
3. *Dampak Noise dan Latar Belakang Kompleks*: Citra CIFAR-10 memiliki keterbatasan kualitas bawaan karena hanya berukuran 32×32 piksel. Ketika gambar beresolusi rendah dikombinasikan dengan latar belakang yang sangat bervariasi, noise spasial meningkat pesat. Kualitas rendah ini sangat memengaruhi performa model *Transfer Learning*. Model MobileNetV2 asli dirancang dan dilatih pada ImageNet dengan resolusi ideal standar 224×224 piksel. Ketika dipaksa menerima input 32×32 tanpa proses upsampling, informasi spasial yang berharga mengalami penyusutan drastis dan ‘hilang’ saat melewati operasi pembongkaran peta fitur di layer-layer awal MobileNetV2, sehingga performanya anjlok mendekati tebakan acak (~54%).

7.2 Analisis Performa Model

1. *Model Terbaik dan Paradoks Akurasi*: Model CNN *from scratch* menghasilkan performa yang jauh lebih baik (Akurasi validasi 72,50%) dibandingkan MobileNetV2 dalam skenario spesifik ini. Hal ini membuktikan bahwa akurasi tinggi pada training tidak menjamin keandalan mutlak, melainkan kesesuaian antara dimensi fisik data dengan kapabilitas pemrosesan arsitektur internal jaringan jauh lebih krusial.
2. *Tanda-Tanda Overfitting dan Stabilitas Training*: Model CNN *from scratch* menunjukkan gejala overfitting yang jelas mulai epoch ke-10, di mana loss validasi cenderung stagnan atau naik tipis (0.55) sementara loss training terus ditekan ke bawah hingga mencapai 0.34. Meskipun demikian, grafik perkembangan performa model dari nol ini berjalan stabil karena dikawal ketat oleh implementasi regularisasi *Batch Normalization* dan *Dropout* pada setiap blok layer.

7.3 Analisis Pemilihan Pendekatan: Kapan Memilih yang Tepat?

Berdasarkan intisari eksperimen, keputusan pemilihan arsitektur harus mematuhi aturan baku berikut:

- Gunakan CNN From Scratch jika: Ukuran dimensi fisik gambar masukan sangat kecil (seperti 28×28 atau 32×32), karakteristik objek bersifat sangat spesifik/terisolasi, dan arsitektur pretrained populer tidak menyediakan variasi resolusi rendah.
- Gunakan Transfer Learning jika: Citra masukan memiliki resolusi menengah hingga tinggi (minimal 96×96 atau idealnya 224×224 ke atas), ketersediaan data training di lokal sangat terbatas (di bawah seribu gambar), serta keterbatasan waktu dan kapasitas komputasi GPU menuntut konvergensi model yang cepat.

8 Studi Kasus Pengambilan Keputusan (Skenario Dunia Nyata)

- Skenario 1: Klinik Medis dengan Keterbatasan Data (300 Gambar Medis)
Rekomendasi Keputusan: Transfer Learning dengan strategi Fine-Tuning Terbatas.
Argumentasi Teknis: Melatih CNN dari dasar dengan hanya 300 gambar dipastikan

akan mengalami kegagalan akibat overfitting ekstrem; model hanya akan menghafal pixel data training tanpa mampu melakukan generalisasi. Meskipun citra medis (seperti X-Ray atau MRI) memiliki karakteristik visual yang berbeda dari ImageNet (yang berisi objek umum seperti hewan dan kendaraan), layer-layer awal pretrained model (seperti ResNet atau DenseNet) tetap menyimpan ekstraktor fitur dasar universal yang sangat andal, seperti deteksi garis tegas, batas tepi, kontur lengkung, dan gradien warna. Dengan melakukan pembekuan layer awal dan membuka beberapa layer atas (fine-tuning) disertai penyesuaian resolusi input ke 224×224 , model mampu beradaptasi mengenali anomali medis secara akurat dalam waktu singkat meskipun data sangat minim.

- Skenario 2: Perusahaan dengan 1 Juta Gambar Produk Internal Non-ImageNet
Rekomendasi Keputusan: CNN From Scratch (Melatih dari Awal) adalah SANGAT RELEVAN dan Direkomendasikan.
Argumentasi Teknis: Volume data sebesar 1 juta citra adalah aset yang sangat masif dan ideal untuk melatih model deep learning berskala besar dari awal tanpa bayang-bayang risiko overfitting. Karena karakteristik produk internal perusahaan tersebut sangat kontras dan tidak memiliki kemiripan dengan kategori objek di ImageNet, bobot pretrained dari luar justru berisiko membawa bias fitur yang tidak relevan (*negative transfer*). Dengan melatih arsitektur khusus dari nol didukung infrastruktur komputasi yang memadai, filter konvolusi akan murni belajar mengekstrak representasi geometris dan esensi visual unik dari produk internal tersebut secara optimal, menghasilkan akurasi dan ketahanan model yang jauh lebih superior di lingkungan produksi.
- Skenario 3: Prototipe Cepat dalam 2 Hari dengan 500 Gambar
Rekomendasi Keputusan: Transfer Learning (Feature Extraction murni).
Argumentasi Teknis: Batasan waktu yang sangat ketat (dua hari) menuntut efisiensi kerja yang maksimal. Membangun CNN dari awal akan menghabiskan waktu berharga untuk eksperimen trial-error menentukan kombinasi arsitektur, parameter, hiperparameter serta risiko kegagalan konvergensi. Dengan memanfaatkan strategi Feature Extraction pada model matang seperti MobileNetV2 atau VGG16, proses pelatihan hanya akan memperbarui bobot pada lapisan *top classifier* yang memiliki jumlah parameter sangat sedikit (hanya ribuan parameter). Proses training ini dapat selesai dalam hitungan menit dengan tingkat akurasi prototipe awal yang stabil dan langsung siap dipresentasikan.
- Skenario 4: Dataset Besar, GPU Memadai, dan Domain Sangat Spesifik
Rekomendasi Keputusan: Transfer Learning tetap diperlukan tetapi dikombinasikan dengan Full Fine-Tuning atau inisialisasi bobot.
Argumentasi Teknis: Meskipun ketersediaan data melimpah dan didukung GPU berdaya tinggi untuk melatih dari awal, membuang bobot ImageNet secara total terkadang kurang efisien. Pendekatan terbaik adalah memuat model pretrained (misalnya EfficientNet) dengan bobot ImageNet sebagai titik inisialisasi (*weight initialization*) awal yang cerdas, alih-alih memulai dari angka acak (*random initialization*). Selanjutnya, setel seluruh jaringan menjadi dapat dilatih (*trainable = True*) dengan menerapkan *learning rate* yang sangat kecil (misalnya 10^{-5}). Strategi ini mempercepat waktu konvergensi secara signifikan dan memanfaatkan pola fitur universal yang sudah ada, sekaligus memberikan kebebasan penuh bagi model untuk mendesain ulang filter internalnya agar selaras dengan domain spesifik yang dituju.

9 Kesimpulan dan Refleksi Pribadi

9.1 Kesimpulan Eksperimen

Eksperimen ini memberikan konklusi penting bahwa pemilihan strategi deep learning tidak dapat didasarkan pada asumsi umum bahwa transfer learning selalu mengungguli model buatan sendiri. Keberhasilan model ditentukan oleh keharmonisan antara dimensi spasial input data dengan arsitektur internal jaringan neural. Jaringan CNN *from scratch* yang dirancang secara minimalis namun presisi berhasil memenangkan performa klasifikasi pada citra resolusi mikro CIFAR-10 (32×32), sementara MobileNetV2 mengalami kendala underfitting struktural yang parah karena kehilangan detail spasial esensial akibat perbedaan skala input bawaan.

9.2 Refleksi Pribadi (Menjawab Pertanyaan Wajib)

1. Apa tantangan terbesar saat mengerjakan tugas ini?
Tantangan terbesar dalam pengerjaan tugas ini adalah mendiagnosis dan menganalisis secara mendalam mengapa model transfer learning MobileNetV2 menghasilkan performa buruk ($\sim 54\%$) pada dataset CIFAR-10. Hal ini melatih kemampuan analisis kritis saya untuk tidak hanya melihat angka akurasi, melainkan memeriksa kesesuaian aspek arsitektural internal jaringannya.
2. Bagian mana yang paling sulit: CNN from scratch atau transfer learning? Mengapa?
Bagian paling sulit adalah melakukan tuning arsitektur CNN *from scratch*. Menentukan jumlah filter yang optimal, posisi peletakan *Batch Normalization*, serta mengontrol nilai probabilitas *Dropout* agar model mampu mencapai akurasi validasi di atas 70% tanpa terjerumus ke dalam jurang overfitting ekstrem memerlukan banyak eksperimen iteratif.
3. Apa perbedaan paling terasa antara melatih model dari awal dan menggunakan pretrained model?
Perbedaan paling mencolok terletak pada kecepatan konvergensi dan fleksibilitas struktur. Melatih model dari nol memberi kebebasan penuh dalam mendesain bentuk input dan alur layer namun membutuhkan perhatian ekstra pada regulasi loss. Sebaliknya, pretrained model terasa sangat instan dan stabil dalam proses training parameter classifier-nya, namun kaku terhadap modifikasi dimensi input tanpa penanganan preprocessing tambahan.
4. Jika tugas ini digunakan untuk kasus nyata, pendekatan mana yang akan Anda pilih?
Di industri nyata, saya akan memprioritaskan pendekatan Transfer Learning yang dikombinasikan dengan teknik *Upscaling / Input Resize Layer* jika resolusi data rendah, atau langsung menggunakan data beresolusi tinggi. Alasan utamanya adalah efisiensi biaya operasional, kecepatan komputasi, dan keandalan fitur bawaan yang telah teruji pada miliaran gambar.
5. Hal Baru yang Dipelajari:
Pelajaran baru yang paling berharga adalah mengenai pengambilan keputusan arsitektur dalam deep learning. Saya menyadari bahwa tidak ada solusi satu-untuk-semua (*no free lunch theorem*). Setiap keputusan desain model wajib mempertimbangkan batasan fisik data (resolusi), batasan sumber daya (waktu dan GPU), serta target spesifisitas dari domain bisnis yang dihadapi.